

Arquitecturas importantes del Deep Learning

A continuación, haremos una breve descripción de algunas de las arquitecturas más importantes del Deep Learning.

Redes neuronales convolucionales

Una de las arquitecturas importantes en Deep Learning son las redes neuronales convolucionales o CNNs por sus siglas en inglés. El término "red neuronal convolucional" indica que la red emplea una operación matemática llamada convolución. La convolución es un tipo especializado de operación lineal que filtra la información y extrae características de los datos para "ayudar" al modelo a encontrar patrones ocultos en la información. El éxito de las redes convolucionales está en las capas convolucionales, que actúan como una 'lupa inteligente', escaneando la información y detectando patrones simples en las capas iniciales, como por ejemplo bordes y texturas en una imagen. Luego, otras capas convolucionales agrupan la información para resaltar las características más importantes. Es como si estuviéramos capturando gradualmente detalles cada vez más complejos, desde líneas hasta formas y objetos completos. Esto nos permite que la red convolucional "aprenda" a reconocer, detectar y clasificar elementos en la información de entrada de manera efectiva, extrayendo las características que codifican y representan una estructura de datos espacial. La **Figura 1** muestra un ejemplo de arquitectura de una red neuronal convolucional usada para clasificación.

Las CNN's han sido particularmente exitosas en tareas de clasificación, segmentación y detección en información como imágenes, videos y series de tiempo. Podemos encontrar aplicaciones en áreas como el reconocimiento facial, sistemas avanzados de detección de objetos en vehículos autónomos y diagnóstico médico a partir de imágenes. Se han empleado en el análisis energético con mapas solares y estimación agrícola mediante imágenes de cultivos adquiridas por satélites o drones, entre otras aplicaciones. También han sido utilizadas en procesamiento de señales

unidimensionales. Por ejemplo, monitoreo en tiempo real de electroencefalogramas y en detección de daño estructural en edificios.




Figura 1. Ejemplo ilustrativo de la arquitectura de una red neuronal neuronal convolucional.

Redes neuronales recurrentes

Continuamos ahora en las Redes Neuronales Recurrentes, también conocidas como RNN por sus siglas del idioma inglés. Son también un tipo de red neuronal diseñadas para tratar con información secuencial o dependiente del tiempo, a diferencia de las redes neuronales convolucionales que tratan con información espacial. Las RNNs fueron diseñadas para manejar datos secuenciales al modelar dependencias temporales. Su capacidad para capturar patrones a lo largo del tiempo y su adaptabilidad a tareas complejas las convierten en una herramienta valiosa para aplicaciones que involucran secuencias, y su profundidad juega un papel clave en su capacidad para comprender y procesar datos secuenciales de manera efectiva. La arquitectura de las RNN se identifica por presentar las conexiones recurrentes que permiten tomar decisiones ponderando la información previa en el contexto actual. La **Figura 2** ilustra la arquitectura de una red neuronal recurrente.

Si consideramos un ejemplo donde la entrada es un párrafo, las RNN no solo analizan cada palabra individualmente, sino que también capturan cómo las palabras se interconectan. Esto les habilita

para entender la información previa y la coherencia del texto, lo que se traduce en aplicaciones como la generación automática de subtítulos para videos o la predicción de series de tiempo. Estas arquitecturas han sido muy exitosas en aplicaciones como procesamiento del lenguaje natural, el reconocimiento de voz, y predicción de sismos y series de tiempo en general.




Figura 2. Ejemplo ilustrativo de la arquitectura de una red neuronal recurrente.

Transformers de lenguaje

En 2017 surgieron los Transformers como alternativa a las redes recurrentes para el procesamiento de lenguaje natural. La novedad de estas arquitecturas es que poseen un mecanismo de atención que cuantifica la importancia relativa de cada palabra de la frase de entrada para asignarle un significado global. A diferencia de las RNNs y las CNNs que se basan en estructuras secuenciales o convolucionales, los Transformers se fundamentan en el concepto de atención. Esta arquitectura se ha destacado por su capacidad para capturar relaciones de largo alcance y comprender contextos complejos en datos secuenciales.

Para comprender las relaciones entre palabras en oraciones complejas, las arquitecturas de Transformers implementan simultáneamente múltiples mecanismos (o cabezas) de auto-atención. Por ejemplo, al analizar la frase “el animal no cruzó la calle porque él estaba muy asustado” como se muestra en la **Figura 3**, para entender el significado del pronombre personal “él”, una cabeza

enfoca su atención en el antecedente “el animal” y otra en el participio “asustado”. A diferencia de las RNN, que necesitan pasar información a lo largo de la secuencia paso a paso, los Transformers pueden considerar toda la secuencia en un solo paso. Y no solo observan su contexto histórico, sino también evalúan la importancia relativa de los eventos pasados.




Figura 3. Ejemplo del mecanismo de atención en un Transformer de lenguaje.

Las aplicaciones de las arquitecturas Transformers son vastas y han dejado huellas en muchos campos. Una de las áreas más impactantes es el procesamiento de lenguaje natural (NLP). Los Transformers han revolucionado cómo entendemos y generamos lenguaje. Desde traducción automática y chatbots inteligentes hasta la manipulación de objetos a través de mecanismos robóticos, estas arquitecturas permiten que las máquinas comprendan y generen texto de manera cercana a como un humano lo haría.

Transformers de visión

El éxito de los Transformers en el campo del procesamiento del lenguaje natural dio origen a los Transformers Visuales. Podemos entender a esta arquitectura como una adaptación del mecanismo de auto-atención pero diseñada para establecer relaciones ponderadas y contextuales entre

pequeños 'parches' de una imagen. Estas arquitecturas dividen las imágenes en una secuencia de parches para asemejarse a las palabras en una oración y utilizan la atención para encontrar las regiones de la imagen que son más importantes para cada tarea específica. Su capacidad para procesar datos visuales de manera similar a cómo los Transformers originales procesan el lenguaje ha desencadenado un avance en tareas como la detección de objetos, la segmentación de imágenes y la generación de contenido visual. Esta adaptación de los Transformers al dominio visual marca un hito en el Deep Learning y ha abierto puertas a aplicaciones emocionantes.

Redes generativas adversariales

Las Redes Generativas Adversariales, o GANs por sus siglas en inglés, introducen una dinámica única en el aprendizaje profundo, donde dos redes neuronales una generadora y una discriminadora compiten en una especie de 'juego' creativo. Imagina a estas redes como un pintor y un crítico de arte que trabajan juntos para crear y evaluar obras dramáticas, respectivamente. La red generadora, como el pintor, crea muestras que se asemejan a ciertos datos de entrenamiento, como imágenes de rostros humanos o paisajes. La red discriminadora, como el crítico, intenta discernir si las muestras provienen del conjunto de datos reales o son creaciones generadas por la red generadora. A medida que pasa el tiempo el artista mejora su habilidad para engañar al crítico y el crítico se vuelve más perspicaz, ambos evolucionan y mejoran en su oficio. Este proceso de competencia mutua resulta en una mejora constante en la calidad de las muestras generadas.

Este tipo de arquitectura permite la generación de datos estructurados, como las imágenes, esto ha tenido un impacto significativo en áreas como el diseño gráfico, la moda y la creación de contenido visual. Además de la generación, las GANs también han encontrado aplicaciones en la manipulación de imágenes, como la traducción de estilo y la mejora de resolución. Otro campo donde las GANs se destacan es en la creación de contenido audiovisual. Pueden generar videos y animaciones realistas a partir de imágenes fijas, lo que es de gran utilidad en la industria del entretenimiento y la publicidad. La **Figura 4** muestra imágenes generadas por el generador de una GAN que se asemejan a personas reales.



Figura 4. Ejemplo de las imágenes generadas artificialmente usando la red generadora entrenada en una GAN. Ninguna de estas personas es real. Generada a través del portal <https://thispersondoesnotexist.com/>.

Modelos probabilísticos de difusión

Los modelos de difusión, que comparten similitudes con el funcionamiento de las GANs, desempeñan un papel crucial en la generación de nueva información. En este enfoque, se inicia con un proceso de difusión que implica la adición gradual de ruido a los datos, como en el caso de una imagen. Esta adición progresiva de ruido tiene el efecto de alterar y degradar la información original. El modelo probabilístico de difusión, que persigue la creación de contenido original, se enfoca en el proceso contrario: la recuperación de la información original a partir de su versión degradada. A través de este enfoque, se busca modelar cómo los datos originalmente corruptos pueden ser restaurados y esto genera información original similar a la información de entrada. La **Figura 5** ilustra el proceso de recuperación.



Figura 5. Ejemplo del proceso de generación en un modelo probabilístico de difusión.

Bibliografía

Prince, Simon J. D. (2023). Understanding Deep Learning. The MIT Press. Disponible en: <https://udlbook.github.io/udlbook/>



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
