

Retos del Deep Learning

¿Cuándo usar modelos de Deep Learning?

Criterios basados en:

- La representación de los datos
- La información a priori que poseemos
- La capacidad para explicar o interpretar los modelos obtenidos





Retos del Deep Learning

Interpretabilidad en los modelos:


- Alta transparencia en los modelos: entender por qué y cómo hace las predicciones
- Interpretar las características y pesos obtenidos para determinar la salida

Explicabilidad en los modelos:

- Cómo tomar un modelo de ML y explicarlo en términos “humanos”
- Para modelos complejos, se pueden usar métodos agnósticos como SHapley Additive exPlanations (SHAP), gráficos de dependencias, entre otros.



Retos del Deep Learning



Accuracy vs interpretability trade-off

Tomado de Arrieta, A. B., Díaz-Rodríguez, N., Del Ser, J., Benetot, A., Tabik, S., Barbado, A., ... & Herrera, F. (2020). Explainable Artificial Intelligence (XAI): Concepts, taxonomies, opportunities and challenges toward responsible AI. *Information fusion*.

Retos del Deep Learning

nature machine intelligence

Explore content ▾ About the journal ▾ Publish with us ▾ Subscribe

[nature](#) > [nature machine intelligence](#) > [perspectives](#) > [article](#)

Perspective | Published: 13 May 2019

Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead

[Cynthia Rudin](#) 

[Nature Machine Intelligence](#) **1**, 206–215 (2019) | [Cite this article](#)

76k Accesses | 3236 Citations | 504 Altmetric | [Metrics](#)



[reprint version](#) of the article is available at arXiv.





Geoffrey Hinton 
@geoffreyhinton


Suppose you have cancer and you have to choose between a black box AI surgeon that cannot explain how it works but has a 90% cure rate and a human surgeon with an 80% cure rate. Do you want the AI surgeon to be illegal?

[Traducir post](#)


3:37 p. m. · 20 feb. 2020

Redes neuronales vs SVM






Neuronas en serie y paralelo con funciones de activación no lineales en las capas ocultas



Redes neuronales

Aproximación de una función no lineal



Redes neuronales

¿De dónde viene el poder de las redes neuronales?

The Universal Approximation Theorem:

Una red neuronal con al menos una capa oculta, y un número suficiente de neuronas, y una función de activación no lineal puede aproximar cualquier función continua con un nivel arbitrario de exactitud.

Neural Networks, Vol. 2, pp. 359-366, 1989
Printed in the USA. All rights reserved.

0893-6005/89 \$3.00 + .00
Copyright © 1989 Pergamon Press plc


ORIGINAL CONTRIBUTION

Multilayer Feedforward Networks are Universal Approximators


KURT HORNIK
Technische Universität Wien



MANUELL STIRCHCOMBE AND HALBER WHITE
University of California, San Diego

Abstract—This paper rigorously establishes that standard multilayer feedforward networks with as few as one hidden layer using arbitrary squashing functions are capable of approximating any Borel measurable function from one finite dimensional space to another to any desired degree of accuracy, provided sufficiently many hidden units are available. In this sense, multilayer feedforward networks are a class of universal approximators.








Redes neuronales







Redes neuronales





Redes neuronales




¡Clasificador lineal sobre este espacio!

Queremos un clasificador $g(o) = w^T o + b$ que sea tal que:


- Los datos de una clase (clase -1) estén a un lado del plano:
 $g(o) < 0$
- Los datos de la otra clase (clase +1) estén al otro lado del plano:
 $g(o) > 0$

Maximizar el margen entre el clasificador y los datos de ambas clases



Máquinas de soporte vectorial

Maximizar el margen entre el clasificador y los datos de ambas clases



Queremos un clasificador $g(x) = w^T x + b$ que sea tal que:

- Los datos de una clase (clase -1) estén a un lado del plano:

$$g(x) < 0$$

- Los datos de la otra clase (clase +1) estén al otro lado del plano:

$$g(x) > 0$$

Queremos clasificar x tal que:

- Si es de clase -1, entonces :


$$g(x) = \sum_{j=1}^m \alpha_j z_j x^T x_j + b < 0$$

- Si es de clase +1, entonces :


$$g(x) = \sum_{j=1}^m \alpha_j z_j x^T x_j + b > 0$$

Donde :

- z_j es la clase del dato x_j
- α_j multiplicador de Lagrange asociado al vector x_j
- Los α_j son cero cuando x_j no es un vector de soporte



Kernelizar producto punto para generar aproximaciones no lineales



Queremos clasificar x tal que:

- Si es de clase -1, entonces :

$$g(x) = \sum_{j=1}^m \alpha_j z_j k(x, x_j) + b < 0$$

- Si es de clase +1, entonces :


$$g(x) = \sum_{j=1}^m \alpha_j z_j k(x, x_j) + b > 0$$

Donde :

- z_j es la clase del dato x_j
- α_j multiplicador de Lagrange asociado al vector x_j
- Los α_j son cero cuando x_j no es un vector de soporte
- k es el producto punto en un nuevo espacio


Máquinas de soporte vectorial

$$g(\mathbf{x}) = \sum_{j=1}^m \alpha_j z_j k(\mathbf{x}, \mathbf{x}_j) + b$$




$$g(\mathbf{x}) = \sum_{j=1}^m \alpha_j z_j k(\mathbf{x}, \mathbf{x}_j) + b$$

Máquinas de soporte vectorial




Máquinas de soporte vectorial



- Formulación matemática muy bien estudiada
- Podemos diseñar kernels a la medida para diferentes tipos de datos y problemas
- Entrenamiento costoso computacionalmente
- Podrían ofrecer modelos mejor interpretabilidad comparados con redes neuronales.

Redes neuronales



- Representación a partir de operaciones muy básicas
- Cantidad de parámetros a encontrar puede ser bastante grande
- Se pueden definir algoritmos eficientes para resolver el problema de aprendizaje
- Facilidad para definir arquitecturas más complejas