

En 2010 se realizó la primera versión de la competición ImageNet Large Scale Visual Recognition Challenge (ILSVRC), un reto de clasificación basado en el conjunto de datos ImageNet el cual contiene 1.2 millones de imágenes distribuidas en 1000 categorías [1]. En esta competencia la tarea de clasificación era de alta complejidad, por esta razón, la evaluación del rendimiento se realizó utilizando una métrica conocida como "error top 5", que medía la frecuencia con la que la categoría correcta no se encontraba entre las cinco predicciones con mayor confianza del modelo. Esta competencia se celebró anualmente desde el 2010 hasta el año 2017, en el año 2012, un hito significativo ocurrió cuando Geoffrey Hinton y Alex Krizhevsky presentaron la arquitectura AlexNet. Este modelo logró un rendimiento excepcional, con un error top 5 del 15.3%, mientras que el segundo clasificado obtuvo un error del 26.2%. Este logro marcó un punto de inflexión en el campo de la visión por computadora.

La arquitectura de AlexNet




Figura 1. Diagrama de la arquitectura AlexNet. Adaptado de (LearnOpenCV, 2018).

La arquitectura AlexNet, propuesta por Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton, marcó un avance importante en el campo de las redes neuronales convolucionales. Este modelo consta de un total de 8 capas, con la mayoría de ellas siendo capas convolucionales, seguidas de 3 capas completamente conectadas. Las funciones de activación empleadas en las capas de AlexNet corresponden a funciones tipo ReLU (Rectified Linear Unit), estos elementos incluyen las no linealidades del modelo. En la **Figura 1** se puede detallar un diagrama esquemático de la arquitectura AlexNet, se detalla la dimensión de las capas y el tipo de capa, a continuación se describen en mayor detalle algunos elementos de esta arquitectura.

Entrada y salida del modelo

AlexNet, diseñada para el reto ILSVRC, recibe imágenes de entrada de dimensiones 256x256 píxeles. Para garantizar este tamaño de imagen, previamente los datos son escalados y recortados para ajustarse a la resolución. Además, AlexNet recibe imágenes a color, es decir, imágenes con 3 canales: rojo, verde y azul. En caso de que la imagen de ingreso sea a blanco y negro (únicamente 1 canal), el canal de intensidad se replica para obtener los 3 canales de color.

La imagen de 256x256 píxeles se recorta aleatoriamente hasta obtener un cuadro de 227x227 píxeles; esto se hace con el objetivo de aumentar el número de datos disponibles. A pesar de que las imágenes puedan ser muy similares, las pequeñas modificaciones en el recorte le permiten al modelo comprender que, a pesar de que haya leves desplazamientos en la imagen, esta sigue perteneciendo a la misma categoría. El aumento de datos es clave para prevenir el fenómeno de sobreajuste (*overfitting*), en el cual el modelo aprende los patrones del conjunto de entrenamiento de forma excelente, pero sus predicciones no son generalizables al probarlo con datos nuevos.

Capas convolucionales y completamente conexas

En la **Figura 1** observamos un bosquejo de la arquitectura, en la parte superior izquierda se observa el inicio de la red, en donde la entrada tiene dimensiones de 227x227x3 píxeles, representando el tamaño de la imagen y los tres canales de color. Posteriormente, es posible observar una serie de parámetros incluidos en la parte superior del conector flecha, estos parámetros caracterizan y resumen los elementos más relevantes de la capa situada en seguida. En la primera capa, se puede observar que se menciona la abreviatura CONV, esto hace referencia a que es una capa de tipo

convolutiva. También se puede notar el escrito 11x11, el cual hace referencia al tamaño del filtro utilizado para la convolución (que será de 11x11x3 debido a que hay 3 canales). El parámetro *stride*, incluido también en la caracterización de capa, indica el número de píxeles que se desplaza el filtro luego de realizar cada operación de convolución, para la primera capa convolutiva son 4 píxeles. Finalmente, el número de filtros (o *kernels*) indica la cantidad de filtros con pesos entrenables que se utilizan en la capa, en este caso son 96. El número de filtros en una capa convolutiva se convertirá en la profundidad de la siguiente capa. La siguiente ecuación permite calcular el tamaño de salida de la capa denotado como *outputSize*:

$$outputSize = \left(\frac{inputSize - kernelSize}{stride} \right) + 1.$$

En la ecuación *inputSize* corresponde a la dimensión de la entrada de la capa de entrada de la capa (227 en este caso), el tamaño del filtro se denota como *kernelSize* y corresponde a 11 y *stride* es 4. De esta forma, podemos obtener que el tamaño de salida es de 55x55x96, debido a que se utilizaron 96 *kernels*.


Adicionalmente, las capas convolutivas pueden incluir *padding*, operación en la cual se adicionan píxeles en el dato de entrada antes de pasar por la capa convolutiva. Esto suele hacerse para mantener las dimensiones espaciales tras la convolución. En el caso de AlexNet, se utiliza un *padding* de 1, es decir, se añaden píxeles en el borde de la entrada una vez. El valor de los píxeles para esta arquitectura es de cero.

En la **Figura 1** también se encuentran los términos como FC, Max POOL y Softmax. FC significa *Fully Connected* o completamente conectado en español. Estas capas suelen encontrarse en el final de la red y se caracterizan por presentar neuronas que aplican la transformación lineal en todos los elementos del vector de entrada. Es decir, cada elemento de la salida de una capa completamente conectado estuvo influenciado por la totalidad del vector de entrada. El término Max POOL señala la implementación de una capa de *Max Pooling*, capa que realiza una operación especial detallada más adelante, mientras que *Softmax* indica que se emplea esta función de activación sobre la capa

de salida, lo cual permite convertir las salidas de la última capa en una distribución de probabilidad para completar la tarea de clasificación.

Max Pooling

La operación de *Max Pooling* se utiliza para disminuir la resolución espacial de la imagen mientras se mantiene la profundidad de la red. Para esto, se toma una ventana con un tamaño definido, por ejemplo, 3x3, y se toma como resultado de la operación el valor más alto de la ventana. A continuación, se presenta un ejemplo en el cual se tiene una ventana de 3x3 con diferentes valores numéricos y se reduce al seleccionar el máximo valor.



En el caso de AlexNet, utilizaron *Max Pooling* sobrelapado, es decir, escogieron un *stride* de 2 para un tamaño de filtro 3x3, lo que causa que una columna del filtro se sobre lape con la operación anterior en cada iteración.

ReLU

Por otro lado, recordemos que la función de activación no lineal evita que toda la red se pueda expresar como una única combinación lineal. AlexNet utiliza la función de activación *Rectified Linear Unit* (ReLU) después de la salida de cada capa para este fin. La función de activación ReLU convierte todos los números negativos en cero, mientras que aplica la identidad en los números positivos. Esta función se aplica en todas las capas de AlexNet menos, como se explicó previamente, en la capa de salida, en la cual se fija como función de activación *Softmax*.

Aprendizaje por transferencia o *Transfer Learning*

Una gran ventaja de las CNN es que podemos entrenarlas para un problema particular utilizando una estrategia conocida como *Transfer Learning*. El *Transfer Learning* consiste en tomar una arquitectura de CNN, como por ejemplo AlexNet, que ya ha sido preentrenada en un conjunto de datos grande, y luego ajustar sus parámetros a una tarea diferente pero relacionada para la cual tenemos pocos datos de entrenamiento. Esto se conoce como sintonización fina o *fine-tuning*. En lugar de entrenar una CNN desde cero, se aprovecha el conocimiento y las características aprendidas por la red en el conjunto de datos original para mejorar el rendimiento en una tarea específica. Esto ahorra tiempo y recursos, ya que no es necesario entrenar una red completa, y suele dar como resultado modelos de CNN más efectivos para la nueva tarea.

Conclusiones

AlexNet es una arquitectura de red neuronal convolutacional pionera en el campo de la visión por computadora. Esta arquitectura revolucionó el rendimiento en tareas de clasificación de imágenes, principalmente en el conjunto de datos ImageNet. AlexNet incluye elementos como capas convolucionales, capas completamente conectadas y capas de *Max Pooling*, además del uso de funciones de activación tipo ReLU y *Softmax* en su capa de salida, todos estos elementos se han convertido en pilares fundamentales en el diseño de arquitecturas de CNN posteriores. El éxito de esta arquitectura promovió el uso e investigación en arquitecturas de redes neuronales profundas, y sentó las bases para desarrollos futuros en el campo, en particular en el área de visión por computadora.

Bibliografía

Nayak S. (2018). Understanding AlexNet. [Internet]. Tomado de LeanOpenCV.

Hinton, G. E., Krizhevsky, A., & Sutskever, I. (2012). Imagenet classification with deep convolutional neural networks. Advances in neural information processing systems, 25(1106-1114), 1.



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
