

Retos de las redes neuronales recurrentes

Una de las mayores ventajas de las redes neuronales recurrentes (RNN) es que son especialmente aptas para el procesamiento de datos secuenciales/temporales, como precios de acciones, secuencias de video y el procesamiento de lenguaje natural. Sin embargo, el entrenamiento de estas redes conlleva varios desafíos. Uno de los principales es el problema de los gradientes que desaparecen o explotan durante el proceso de entrenamiento. A continuación, vamos a profundizar en cada uno de estos retos.

Desvanecimiento del gradiente

El desvanecimiento del gradiente es un problema común en la optimización de redes neuronales, que se produce cuando los gradientes se vuelven cada vez más pequeños a medida que se propagan hacia las capas anteriores de la red. Este fenómeno se debe en parte al uso de funciones de activación no lineales como la función sigmoide, que tienen una derivada que oscila entre 0 y 0.25. A medida que se propagan los gradientes a través de la red, las derivadas se multiplican y, por lo tanto, los gradientes se vuelven cada vez más pequeños. Esto puede hacer que las capas anteriores de la red tengan un impacto cada vez menor en la actualización de los pesos, lo que limita la capacidad de la red para aprender patrones complejos.

El problema del desvanecimiento del gradiente es especialmente relevante en las redes neuronales recurrentes (RNN), que se utilizan comúnmente para procesar datos temporales. En estas redes, las entradas se procesan secuencialmente, y la salida de cada paso de tiempo se utiliza como entrada para el siguiente paso de tiempo. Esto significa que los gradientes se propagan hacia atrás a través del tiempo, lo que puede agravar el problema del desvanecimiento del gradiente. Si los gradientes se vuelven cada vez más pequeños a medida que se propagan hacia atrás en el tiempo, las capas anteriores de la red pueden tener un impacto cada vez menor en la actualización de los pesos, lo que limita la capacidad de la red para aprender patrones complejos a largo plazo.

Existen varias técnicas que se han propuesto para abordar el problema del desvanecimiento del gradiente en las redes neuronales recurrentes. Una de las más populares es la red de memoria a

largo plazo (LSTM), que utiliza puertas para controlar el flujo de información a través de la red. Estas puertas permiten que la red almacene información relevante durante varios pasos de tiempo, lo que ayuda a mitigar el problema del desvanecimiento del gradiente. Otra técnica popular es la red neuronal de memoria a corto plazo (GRU), que es similar a la LSTM, pero utiliza menos parámetros.

Además de estas técnicas específicas de arquitectura, también existen técnicas de optimización que se pueden utilizar para abordar el problema del desvanecimiento del gradiente. Por ejemplo, el uso de técnicas de normalización como la normalización por lotes o la normalización por capas puede ayudar a estabilizar el entrenamiento y evitar que los gradientes se vuelvan demasiado grandes o demasiado pequeños. También se pueden utilizar técnicas de regularización como la eliminación aleatoria o la eliminación de peso para reducir la complejidad de la red y limitar la propagación de gradientes indeseados.

Explosión de gradientes

La explosión de gradientes es el problema opuesto al desvanecimiento de gradientes. Sucede cuando el valor del gradiente se vuelve extremadamente grande durante el entrenamiento de la red neuronal, lo que hace que los pesos se actualicen en grandes magnitudes y se produzca un comportamiento inestable de la red. Este problema es especialmente común en RNNs con retroalimentación de corto plazo, donde los pesos de las conexiones recurrentes se multiplican repetidamente en el tiempo, lo que puede provocar que los valores del gradiente se disparen.

Al igual que con el desvanecimiento de gradientes, la explosión de gradientes puede provocar problemas de aprendizaje y una mala generalización. Si los valores de los gradientes son demasiado grandes, la red puede actualizar sus pesos agresivamente y terminar divergiendo en lugar de converger a una solución óptima. Esto puede ser especialmente problemático en RNNs que se utilizan para tareas de predicción, donde un modelo inestable puede producir predicciones incorrectas y ser perjudicial para el rendimiento general del sistema.

Una de las formas más comunes de abordar el problema de la explosión de gradientes es mediante el recorte de gradientes. El recorte de gradientes es una técnica que limita el valor máximo del gradiente durante el entrenamiento para evitar que los valores se vuelvan demasiado grandes. El recorte de gradientes se puede implementar en varios puntos durante el proceso de entrenamiento, como después de calcular el gradiente, después de normalizar el gradiente o después de actualizar

los pesos. Al limitar los valores del gradiente, se puede reducir la probabilidad de que se produzca una explosión de gradientes y mejorar la estabilidad del modelo.

Otra forma de abordar el problema de la explosión de gradientes es mediante el uso de arquitecturas de red más complejas, como las redes neuronales recurrentes LSTM y GRU. Estas arquitecturas tienen conexiones recurrentes con compuertas que controlan la cantidad de información que se almacena en la memoria a largo plazo de la red, lo que puede ayudar a mitigar los efectos de la explosión de gradientes y mejorar el rendimiento del modelo. Además, estas arquitecturas también pueden incluir técnicas como el apagado aleatorio y el dropout para regularizar el modelo y prevenir el sobreajuste.

Bibliografía

Graves, A., & Graves, A. (2012). Long short-term memory. *Supervised sequence labelling with recurrent neural networks*, 37-45.

Chung, J., Gulcehre, C., Cho, K., & Bengio, Y. (2014). Empirical evaluation of gated recurrent neural networks on sequence modeling. *arXiv preprint arXiv:1412.3555*.

Ioffe, S., & Szegedy, C. (2015, June). Batch normalization: Accelerating deep network training by reducing internal covariate shift. In *International conference on machine learning* (pp. 448-456). pmlr.

Ba, J. L., Kiros, J. R., & Hinton, G. E. (2016). Layer normalization. *arXiv preprint arXiv:1607.06450*.



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
