

Transformers: Codificación de texto

Cuando se quiere ingresar un fragmento de texto a un Transformer o a una red neuronal para que sea procesado, es importante primero convertirlo a un formato que la máquina pueda entender. A partir de esa necesidad, surgieron diferentes métodos para que esta información no solamente sea reconocida por la máquina, sino que también mantenga su significado semántico.

One hot encoding

Una de las formas más sencillas de convertir información categórica a número es a través de one hot encoding. En este tipo de codificación, se convierte cada valor categórico (por ejemplo, cada palabra) en un vector binario. A continuación, la **Figura 1** muestra cómo cada palabra tiene asignada una posición en el vector.

Palabra	Codificación
El	[1 0 0 0]
Perro	[0 1 0 0]
Es	[0 0 1 0]
Blanco	[0 0 0 1]

Figura 1. Ejemplo de one hot encoding en una frase simple.

Si bien el one hot encoding es una forma sencilla de transformar datos categóricos a numéricos, este tipo de codificación no mantiene ningún significado semántico de las palabras. Por ejemplo, no es posible tomar la información codificada y saber si la palabra es un sustantivo, un adjetivo, un verbo, un artículo o si es un animal. A partir de esta necesidad surgen los modelos de embedding, también llamados modelos de embebimiento o codificación.

Embedding

El embedding, es una representación numérica de la información que puede realizarse en imágenes, sonido, documentos, texto, código, entre otros. Esta técnica convierte la información a un formato que le permite a la máquina comprender las relaciones que hay entre los datos. En el caso de texto, el embedding permite capturar el significado semántico de lo que se está codificando.




Figura 2. Vector de representación a partir de un modelo de embedding.

La **Figura 2** muestra un ejemplo de un vector de representación que se forma a partir de un modelo de embedding sobre la palabra "perro". Si realizamos este proceso con múltiples palabras y medimos las distancias de cada vector de representación en un espacio arbitrario, podemos observar que aquellas palabras con significados semánticos similares se encuentran más cerca. En la **Figura 3**, se muestra un ejemplo de un embedding clásico conocido como Word2vec. En esta figura, se muestra una proyección en dos dimensiones de algunas palabras tras ser codificadas en un espacio de 300 dimensiones con el algoritmo Word2vec.




Figura 3. Espacio de representación del embedding de palabras cotidianas. Las palabras con significados semánticos similares se encuentran a menor distancia.

Modelos de embedding

A diferencia del one hot encoding, para realizar el embedding de los datos es usual utilizar un modelo preentrenado. Algunos ejemplos de modelos de embedding son Instructor, Sentence Transformers y los modelos de OpenAI: Ada, Davinci, Curie y Babbage.

Una vez se obtiene el vector del embedding, es posible utilizar los datos para múltiples tareas. Por ejemplo, es posible medir la distancia de las representaciones de dos frases para ver si tienen significados similares. También, es posible pasar una imagen por el modelo de embedding y comparar su espacio de representación con respecto al espacio de una frase para determinar si están relacionadas. Este último ejemplo suele utilizarse en los motores de búsqueda para encontrar imágenes que se asocien al mensaje de la barra de búsqueda. Del mismo modo, esta información también se usa para publicidad en redes sociales.

Conclusiones

El embedding convierte los datos a una representación numérica que mantiene el significado semántico y las relaciones entre la información. Se puede utilizar en múltiples tipos de datos y es comúnmente utilizado en el procesamiento de lenguaje natural. Aquellos vectores que se encuentren relacionados se encontrarán más cerca en el espacio de representación, esta característica se utiliza comúnmente en los motores de búsqueda y en los sistemas automatizados de publicidad.

Bibliografía

Muennighoff, N., Tazi, N., Magne, L., & Reimers, N. (2022). MTEB: Massive Text Embedding Benchmark. ArXiv Preprint ArXiv:2210. 07316. doi:10.48550/ARXIV.2210.07316

OpenAI. (2022). New and Improved Embedding Model. [Internet]. Tomado de: <https://openai.com/blog/new-and-improved-embedding-model>

Espejel, O. (2022). Getting Started With Embeddings. [Internet]. Tomado de: <https://huggingface.co/blog/getting-started-with-embeddings>



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
