

Codificación posicional en Transformers para NLP

En los lenguajes, el orden y la posición de las palabras en una oración son realmente importantes. El significado completo de la oración puede cambiar si se altera el orden de las palabras. Mientras que las redes neuronales recurrentes tienen un mecanismo integrado para manejar el orden de las secuencias al implementar soluciones de procesamiento de lenguaje natural (NLP), el modelo Transformer, por otro lado, no utiliza la recurrencia ni la convolución y trata cada punto de datos de forma independiente. Por lo tanto, es necesario agregar información posicional explícitamente al modelo para preservar el conocimiento del orden de las palabras en una oración. La codificación posicional es el **método mediante el cual se mantiene la información sobre el orden de los elementos en una secuencia.**


En esta lectura, vamos a explicar la codificación posicional para los Transformers. Explicaremos qué es la codificación posicional, por qué es importante y cómo funciona en los Transformers.

¿Qué es la codificación posicional?

La codificación posicional se refiere a la manera en que se asigna una **ubicación o posición única a cada entidad en una secuencia**. Existen varias razones por las que un solo número, como el valor del índice, no se utiliza para representar la posición de un elemento en los modelos de Transformers. En el caso de secuencias largas, los índices pueden volverse demasiado grandes. Además, normalizar el valor del índice entre 0 y 1 puede generar problemas cuando se trabaja con secuencias de longitud variable, ya que se normalizarían de manera diferente.

En cambio, los Transformers emplean un esquema de codificación posicional ingenioso, donde a cada posición o índice se le asigna un **vector específico**. Por lo tanto, la salida de la capa de codificación posicional es una matriz en la que cada fila representa un objeto codificado de la secuencia combinado con su información posicional.

Capa de codificación posicional en los Transformers

**Figura 1.** Estructura del Transformer.

Tomado de: Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30.

En el artículo original que introdujo el Transformer, se presentó una estrategia ingeniosa para representar la posición de cada elemento en una secuencia de entrada. Esta representación posicional es el último paso de procesamiento que se aplica a los datos de entrada antes de pasar por el bloque del encoder, como se ilustra en la **Figura 1**. De esta manera, cuando los datos se introducen en el encoder, ya han adquirido relaciones semánticas a través del input embedding y relaciones de posición mediante el positional embedding. Para comprender mejor cómo funciona esta representación posicional, suponga que nuestra secuencia de entrada consiste de 7 vectores $e_0, e_1, e_2, e_3, e_4, e_5, e_6$. Cada uno de estos vectores tiene dimensión d , pues ya han sido codificados en

un espacio de dimensión alta tras pasar por el input embedding. A cada vector e_{pos} le vamos a asignar otro vector P_{pos} de la misma dimensión d . Este vector P_{pos} va a contener la información que le indica al modelo que el vector e_{pos} se encuentra en la posición número pos de la secuencia. Estos vectores se calculan de la siguiente forma:

$$P_{(pos,2i)} = \sin\left(pos/10000^{\frac{2i}{d}}\right)$$

$$P_{(pos,2i+1)} = \cos\left(pos/10000^{\frac{2i}{d}}\right)$$

La primera ecuación calcula las entradas del vector P_{pos} que están en las posiciones pares, mientras que la segunda ecuación calcula las entradas que están en las posiciones impares. Por eso los subíndices son $2i$ y $2i + 1$. Veamos por qué se utilizan estas funciones. Si fijamos el valor de i en 2 y pensamos que pos es una variable continua, podemos graficar esa primera curva como una función de pos :




Figura 2. Cuarta función de posición.

Luego, tras evaluar esta función en $pos = 0,1,2,3 \dots,6$ obtendremos la cuarta entrada de nuestros vectores de posición para cada elemento de la secuencia. Es decir, la altura de ese seno codifica la posición de cada elemento de la secuencia, pues elementos en posiciones diferentes de la secuencia tendrán valores de codificación distintos. Sin embargo, hay un problema. Dado que la

curva sinusoidal se repite en intervalos, podemos ver en la **Figura 2** que $P_{1,4}$ y $P_{4,4}$ tienen los mismos valores de codificación, a pesar de estar en dos posiciones muy diferentes (las posiciones 1 y 4 en la secuencia respectivamente). Aquí es donde entra en juego la parte i en la ecuación.

Si ahora, variamos el valor de i y graficamos las funciones resultantes obtenemos varias curvas sinusoidales de diferentes frecuencias como se muestra en la **Figura 3**.




Figura 3. Funciones de posición.

La idea detrás de tener varias curvas sinusoidales con diferentes frecuencias es que si tenemos dos elementos que están muy cerca en la secuencia, necesitamos senos con altas frecuencias para detectar que están cerca y que sus valores correspondientes en la curva sinusoidal sean diferentes. Esto se muestra en la **Figura 3** donde podemos ver que para bajas frecuencias a los elementos e_2 y e_4 se les asigna información posicional muy cercana, mientras que en altas frecuencias las curvas sinusoidales les asignan valores posicionales distintos. Cada frecuencia nos ayuda a distinguir qué

tan lejos están los elementos de la secuencia. Esto nos ayuda a solucionar el problema anteriormente mencionado.

De esta forma, logramos asignarle a cada vector e_{pos} de entrada un vector P_{pos} que codifica la posición en la que se encuentra ese elemento en la secuencia. Por ejemplo, en la **Figura 4** se muestra el vector posicional que se obtiene para el tercer elemento de la secuencia. Las entradas en posiciones impares de este vector se calculan de manera similar a las que mostramos, pero con funciones cosenos.




Figura 4. Vectores posicionales.

Codificación Posicional en la práctica

En la práctica, la dimensión de input embedding puede ser muy alta y necesitamos cientos o miles de funciones sinusoidales para calcular el vector posicional para un elemento de una secuencia. En la **Figura 5** se muestra lo que se conoce como una matriz de codificación posicional, es una forma visual de representar la codificación posicional cuando estamos trabajando con input embeddings de dimensiones muy altas o con secuencias de texto muy largas. En el eje x se muestra la posición

del elemento en la secuencia, en este caso una secuencia de 100 tokens. En el eje y se muestra la entrada del vector de posición, en este caso tenemos un input embedding de dimensión 300. El mapa de colores nos muestra el valor de la función sinusoidal para una entrada del vector de posición de un elemento que está en una posición dada en la secuencia de palabras. Por eso los valores en el mapa de color están entre -1 y 1.




Figura 5. *Matriz de codificación posicional*

Bibliografía

- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30.
- Saeed, M. (2023). A gentle introduction to positional encoding in transformer models, part 1. Retrieved from <https://machinelearningmastery.com/a-gentle-introduction-to-positional-encoding-in-transformer-models-part-1/>



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
