

Mecanismo de autoatención en los Transformers para el Procesamiento de Lenguaje Natural

Los Transformers, como modelos de aprendizaje automático, se fundamentan en un mecanismo esencial llamado **autoatención** o **atención de múltiples cabezas** (*multi-head attention* en inglés). Este mecanismo habilita a los Transformers para capturar las relaciones de dependencia entre las palabras en una oración, lo que, a su vez, potencia la calidad y coherencia de los resultados generados. En esta lectura, vamos a explorar el mecanismo de autoatención en los Transformers y su papel esencial en el procesamiento de lenguaje natural. Comenzaremos por entender los conceptos fundamentales de la atención y luego profundizaremos en cómo los Transformers emplean este mecanismo para adquirir representaciones contextuales de las palabras en un texto.

¿Cómo entendemos la atención?

La atención es una capacidad humana que nos permite centrarnos en ciertos elementos y filtrar la información relevante de un conjunto más amplio. En el contexto del Procesamiento de Lenguaje Natural, la atención se refiere a la capacidad de **asignar importancia a diferentes partes de una oración** para comprender y generar texto.

Mecanismo de autoatención

El mecanismo de autoatención en los Transformers se basa en la idea de que cada palabra en una oración puede "atender" a otras palabras para obtener información relevante. En lugar de depender únicamente de contextos locales, como las ventanas de contexto fijas utilizadas en otros modelos, los Transformers permiten que cada palabra atienda a todas las demás palabras de la oración, generando así una mejor representación contextual.

Para entender el mecanismo de autoatención iniciaremos definiendo los siguientes elementos: consultas (Q), llaves (K) y valores (V). Las consultas (Q) se pueden entender como una pregunta que cada palabra hace a las demás. Las llaves (K) se puede pensar como la lista de palabras con las que la palabra que se analiza se puede comparar. Finalmente, los valores (V) se pueden relacionar con guardar la información clave de la palabra de análisis. Estas partes (Q, K y V) se utilizan para ayudar a entender cómo se relacionan todas las palabras en la oración.




Figura 1. Transformación para la creación de las consultas (Q), llaves (K) y valores (V) para un conjunto de tokens que ya tienen representación numérica y posicional.

Para cada palabra de una oración se calculan las consultas (Q), llaves (K) y valores (V). Estos tres elementos se representan como vectores de características y se generan a través de transformaciones lineales independientes de las palabras originales. Dado que no es posible

analizar las palabras en su formato de texto, se utiliza su representación en *tokens* la cual es numérica y posicional. En la **Figura 1** se ilustra cómo las palabras se transforman en estas partes clave. En la figura se utilizó como ejemplo la oración “Cuando juegas muchos videojuegos”, la cual tiene una codificación en una matriz de tamaño 4x4. Particularmente, en este ejemplo se utiliza una transformación de 3 capas. Es decir, la codificación numérica y posicional original se multiplica por una matriz de pesos de tamaño 4x3 específica para las consultas, llaves y valores. Como resultado, se tendrán matrices de 4x3 que almacenan las consultas, llaves y valores de cada palabra.




Figura 2. Cálculo de los pesos de atención utilizando las consultas (Q) y la transpuesta de las llaves (K).

Una vez que hemos calculado las matrices de consulta (Q), llaves (K) y valores (V) para toda la oración utilizamos estos valores en cálculos adicionales para determinar cómo se relacionan las palabras entre sí y para obtener una representación contextual de la oración en su conjunto. En un segundo paso, calculamos los coeficientes de la matriz de atención, conocidos como pesos de atención. Este cálculo se realiza mediante el producto escalar entre la matriz de consulta y la versión transpuesta de la matriz de claves, seguido de aplicar la función *softmax* para normalizar estos pesos. Como resultado, la matriz de atención contiene valores de peso que indican la relevancia relativa de las palabras en función de su similitud con la consulta. Las palabras más relevantes tienen pesos más altos, lo que permite obtener una representación contextual más precisa en base a esta importancia relativa. La representación visual de este proceso se ilustra en la **Figura 2**.

En el tercer paso se combinan los valores (V) ponderándolos según los pesos de atención obtenidos en el paso previo. Esta combinación se realiza calculando la suma ponderada de los valores (V) para cada palabra. Es decir, la matriz de pesos de atención se multiplica matricialmente con los valores (V). Una representación visual de este cálculo se ilustra en la **Figura 3**. El resultado es una representación contextualizada de cada palabra, que captura la información relevante de las palabras vecinas en función de su importancia relativa.



Figura 3. Cálculo de los valores filtrados con los pesos de atención y los valores (V)

Al unir los tres pasos que se han presentado previamente, llegamos a la ecuación de autoatención. Esta fórmula se utiliza para calcular la representación contextual de una palabra en función de su relación con las demás en la oración. La fórmula se puede expresar de la siguiente manera:

$$A(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V.$$

En la ecuación A en función de (Q, K, V) representa la autoatención, Q las consultas, K las llaves, V los valores, y el término $\sqrt{d_k}$ es un factor de escalamiento, con d_k la dimensión de las llaves.

Es fundamental comprender que el mecanismo de autoatención se aplica en múltiples ocasiones dentro de un modelo Transformer. Cada ejecución de este proceso se denomina "cabeza de atención". Los Transformers tienen la flexibilidad de usar múltiples cabezas de atención en paralelo, es decir de manera simultánea, lo que les permite aprender diversas representaciones de las palabras desde diferentes enfoques. Esta característica enriquece la capacidad del modelo para capturar relaciones semánticas complejas desde varias perspectivas.

Además, para abordar la captura de relaciones de largo alcance, se introduce el concepto de **atención con ventana**. En lugar de considerar todas las palabras de la oración, se restringe el alcance de la atención a un conjunto predefinido de palabras vecinas. Esto se logra mediante la incorporación de máscaras que especifican qué palabras tienen permiso para influir en otras palabras en una posición determinada. La atención con ventana permite encontrar un equilibrio entre la complejidad computacional y la captura de dependencias a larga distancia, sin sacrificar la capacidad de modelar relaciones locales.

El mecanismo de autoatención en los Transformers ha demostrado ser una herramienta altamente efectiva en el procesamiento de lenguaje natural. Al permitir que cada palabra interactúe con todas las demás en una oración, los Transformers capturan de manera precisa y exhaustiva las relaciones tanto sintácticas como semánticas entre las palabras. Este enfoque ha impulsado mejoras sustanciales en diversas aplicaciones del Procesamiento de Lenguaje Natural, como la traducción automática, la generación de texto y el análisis de sentimientos, entre otras áreas.

Conclusión

En esta lectura, hemos explorado a fondo el mecanismo de autoatención en los Transformers para el Procesamiento de Lenguaje Natural. La autoatención permite que cada palabra interactúe con todas las demás en una oración, lo que resulta en representaciones contextuales altamente enriquecidas. Este mecanismo ha sido fundamental en el éxito de los modelos basados en Transformers en una amplia variedad de tareas de Procesamiento de Lenguaje Natural.

El entendimiento de cómo opera la autoatención en los Transformers proporciona bases para abordar desafíos en el Procesamiento de Lenguaje Natural y explorar investigaciones futuras en este campo que está en constante evolución. Los Transformers y su mecanismo de autoatención continúan impulsando avances significativos en el campo del Procesamiento de Lenguaje Natural, y su comprensión es esencial para aprovechar plenamente el potencial de la Inteligencia Artificial en el análisis y generación de texto.

Bibliografía

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., ... & Polosukhin, I. (2017). Attention is all you need. Advances in neural information processing systems, 30.



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
