

Metodología de entrenamiento: Función de pérdida en las Redes Generativas Adversariales.

Las Redes Generativas Adversariales (GANs, por sus siglas en inglés) han surgido como un marco poderoso en el campo del aprendizaje automático para generar datos sintéticos realistas y de alta calidad. Las GANs emplean una arquitectura particular que consiste en dos redes neuronales, el generador y el discriminador, las cuales participan en un proceso de aprendizaje competitivo. El generador tiene como objetivo producir muestras sintéticas que se asemejen a datos reales, mientras que el discriminador intenta distinguir entre muestras reales y falsas. El éxito de las GANs depende de la optimización efectiva de estas dos redes, y en el centro de esta optimización se encuentra la elección de una función de pérdida adecuada. La función de pérdida sirve como una métrica orientadora para cuantificar el rendimiento de las redes del generador y el discriminador. En este texto, nos adentraremos en las complejidades de las funciones de pérdida utilizadas en las GANs y exploraremos cómo influyen en la dinámica de entrenamiento y la calidad final de la salida.

En el contexto de la red del generador, el objetivo principal es generar muestras sintéticas que sean indistinguibles de los datos reales. Esto implica la definición de una función de pérdida adecuada que cuantifique la discrepancia entre las muestras generadas y la distribución de datos reales. Exploraremos funciones de pérdida comunes utilizadas en el generador, como la divergencia de Jensen-Shannon y la distancia de Wasserstein, arrojando luz sobre sus ventajas y limitaciones.

Por otro lado, la red del discriminador tiene como objetivo clasificar correctamente las muestras como reales o falsas. Para lograr esto, es crucial utilizar una función de pérdida que guíe de manera efectiva el proceso de aprendizaje del discriminador. Por esto, examinaremos funciones de pérdida utilizadas para el discriminador, como la entropía cruzada binaria (cross-entropy loss) y la hinge loss,

y aclararemos cómo facilitan el entrenamiento del discriminador y contribuyen a la dinámica adversarial general.

Funciones de pérdida




Figura 1. Ejemplo de una Red Generativa Adversaria (GAN). El generador crea imágenes nuevas basadas en el conjunto de datos de entrenamiento, mientras que el discriminador aprende a diferenciar las imágenes originales de las imágenes generadas.

En las GANs, generador y el discriminador están involucrados en un proceso de aprendizaje competitivo, cada una con su propia función de pérdida distintiva. El generador busca minimizar la función de pérdida asociada a la diferencia de las imágenes generadas y las imágenes reales, mientras que el discriminador busca maximizar su habilidad para discriminar los datos generados de los reales. En el primer trabajo donde las GANs fueron presentadas, Ian Goodfellow propone esta forma de aprendizaje como un juego de dos jugadores conocido en la teoría de juegos como minimax. En este juego, el jugador correspondiente al generador busca minimizar la diferencia entre las imágenes generadas y las imágenes reales, y el jugador asociado al discriminador busca maximizar la habilidad para discriminar los datos generados de los reales. Bajo esta propuesta se definió una función objetivo a minimizar de la cual se derivaron la función de pérdida para el generador y la función de pérdida para el discriminador. Después del trabajo seminal por Goodfellow se han propuesto funciones de pérdida más sofisticadas que permiten obtener mejores resultados de generación, de las cuales listamos algunas a continuación.

Función de Pérdida para el Generador:

El objetivo principal de la red del generador en una GAN es generar muestras sintéticas que se asemejen estrechamente a los datos reales. La función de pérdida del generador cuantifica la discrepancia entre las muestras generadas y la distribución de datos reales, proporcionando una medida de qué tan bien está funcionando el generador. Dos funciones de pérdida comúnmente utilizadas para el generador son:

a) Divergencia de Jensen-Shannon:

La divergencia de Jensen-Shannon (JSD) es una elección popular de función de pérdida en las GAN. Ésta mide la similitud entre dos distribuciones de probabilidad, y se deriva de otra llamada Kullback-Leibler. La pérdida de JSD tiene como objetivo minimizar la diferencia entre la distribución de las muestras generadas y la distribución de las muestras reales. Minimizar la pérdida de JSD alienta al generador a producir muestras que sean indistinguibles de los datos reales.

b) Distancia de Wasserstein:

La distancia de Wasserstein es otra función de pérdida utilizada en las GANs. Proporciona una métrica para cuantificar la disparidad entre dos distribuciones de probabilidad. La función de pérdida de la distancia de Wasserstein alienta al generador a minimizar la diferencia entre la distribución de las muestras generadas y la distribución de los datos reales. Una ventaja de la distancia de Wasserstein es que proporciona un paisaje de optimización más estable en comparación con otras funciones de pérdida, mitigando problemas como el hecho de que el generador sólo genera un tipo de salida, conocido como problema del colapso del modo (*mode collapse*, en inglés).

El colapso del modo en una GAN ocurre cuando el Generador se enfoca en generar muestras exclusivamente de un conjunto limitado de datos concentrados alrededor de un modo de la distribución de los datos, tratando de engañar al Discriminador. Esto resulta en la falta de diversidad en las muestras generadas, ya que el Discriminador eventualmente lo descubre y el Generador cambia a otro modo, repitiendo este ciclo indefinidamente. Esto limita la variedad de las muestras generadas y reduce la efectividad del Generador para engañar al Discriminador.

Función de Pérdida para el Discriminador:

La red del discriminador en una GAN tiene como objetivo clasificar correctamente las muestras como reales o falsas. La función de pérdida para el discriminador está diseñada para guiar su proceso de aprendizaje al proporcionar una señal para distinguir entre muestras reales y generadas. Dos funciones de pérdida comúnmente utilizadas para el discriminador son:

a) Cross-entropy loss:

La Cross-entropy loss es una función de pérdida ampliamente utilizada para tareas de clasificación binaria, incluido el discriminador en una GAN. Mide la disparidad entre las probabilidades de clase predichas y las etiquetas de verdad. El objetivo del discriminador es minimizar esta pérdida, clasificando correctamente las muestras reales como reales (etiqueta 1) y las muestras generadas como falsas (etiqueta 0).

b) Hinge loss:

La Hinge loss (o pérdida de bisagra) es otra función de pérdida comúnmente utilizada para entrenar el discriminador en las GANs. La Hinge loss fomenta un margen entre las predicciones del discriminador para muestras reales y generadas. Al minimizar la pérdida de bisagra, el discriminador busca lograr una separación clara entre las muestras reales y falsas, facilitando una discriminación más efectiva.

Es importante tener en cuenta que la elección de las funciones de pérdida en las GANs puede variar según los requisitos específicos de la tarea y las propiedades deseadas de las muestras generadas. Los investigadores a menudo exploran nuevas funciones de pérdida o variaciones de las existentes para abordar desafíos específicos y mejorar la dinámica de entrenamiento de las GANs.

Bibliografía

Goodfellow, I., Pouget-Abadie, J., Mirza, M., Xu, B., Warde-Farley, D., Ozair, S., ... & Bengio, Y. (2014). Generative adversarial nets. Advances in neural information processing systems, 27.



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
