

Metodología de entrenamiento de un Modelo Probabilístico de Difusión

Problema de aprendizaje

El objetivo de un modelo de difusión es generar datos sintéticos realistas, que se parezcan a los datos de entrenamiento. Para hacer esto, tomamos una gran cantidad de datos con los que vamos a entrenar, por ejemplo, imágenes. Si tenemos muchas imágenes, podemos pensar que estas imágenes son todas muestreadas de una distribución que llamamos $q(x_0)$. Podemos considerar que esta distribución modela las probabilidades de obtener una imagen pueda venir de nuestra base de datos. Es decir, imágenes que 'tienen sentido' tienen altas probabilidades de ocurrencia, mientras que imágenes no estructuradas como el ruido tienen bajas probabilidades de ocurrencia.

En principio, no conocemos esta distribución $q(x_0)$. Sólo tenemos una cantidad finita de muestras de esta distribución que son nuestros datos de entrenamiento. Además, esta distribución puede ser extremadamente compleja. Por ejemplo, para imágenes podríamos modelar una distribución en dimensión $256 \times 256 \times 3$, la cual sería altamente compleja. Los modelos probabilísticos de difusión nos ayudan entonces a *estimar* esta distribución durante el proceso de entrenamiento. Una vez tengamos una aproximación de $q(x_0)$, podremos tomar muestras de esta distribución y obtener imágenes nuevas sintéticas, que en cierto sentido se parecerán a las imágenes de entrenamiento.

El proceso de difusión forward

El modelamiento de los procesos de difusión nos ayudará a aproximar esta distribución $q(x_0)$ de la siguiente forma. Recuerde que en el proceso forward lo que hacemos es tomar uno de nuestros datos que hemos asumido que son una muestra de la distribución $q(x_0)$, esto lo denotamos como

$x_0 \sim q(x_0)$. Luego, por medio del proceso forward, corrompemos esta muestra con ruido en pasos iterativos y generamos una secuencia de imágenes $x_0, x_1, \dots, x_T$ donde x_T termina siendo una imagen que es virtualmente ruido puro. Recuerde que esto lo modelamos de manera precisa como: $q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$. Es decir, conocemos exactamente la distribución que nos modela qué imagen obtenemos en el tiempo t , dado que conocemos qué imagen tenemos en tiempo $t - 1$. En la **Figura 1** se muestra de forma gráfica qué sucede con el proceso forward.




Figura 1. Durante el proceso forward transformamos la distribución inicial de los datos $q(x_0)$ que puede ser muy compleja en una distribución normal estándar $q(x_T)$ que es más sencilla.

Mientras avanzamos en el proceso forward y vamos añadiendo más ruido, vamos transformando la distribución $q(x_0)$ en una distribución más sencilla. Como al final del proceso forward obtenemos una imagen x_T que es prácticamente ruido, decimos que esta última imagen sigue una distribución normal estándar. Esto lo denotamos como $x_T \sim q(x_T)$, donde $q(x_T) = \mathcal{N}(x_T; 0, I)$.

El proceso reverso de difusión

La estrategia para aproximar $q(x_0)$ consistirá en aprender cómo ‘devolvernos’ por los caminos que traza el proceso forward. Es decir, queremos partir de una imagen que sea ruido puro x_T muestreada

de $q(x_T)$ y 'revertir' el proceso forward. Es decir, generar una secuencia de imágenes $x_T, x_{T-1}, \dots, x_0$ donde vamos quitando el ruido progresivamente siguiendo los caminos reversos del proceso forward. La última imagen de esta secuencia x_0 , será una imagen que ha sido muestreada de la distribución $q(x_0)$, es decir, una nueva imagen que sigue la misma distribución ideal de nuestros datos. Esto lo podemos garantizar porque quitamos el ruido de una manera muy precisa: siguiendo el camino reverse del proceso forward. Esto se ilustra en la **Figura 2**.




Figura 2. Los caminos amarillos ilustran el proceso reverse, en los cuales partimos de un dato x_T muestreado de $q(x_T)$ y queremos llegar a un dato x_0 muestreado de la distribución $q(x_0)$.

Sin embargo, para poder devolvernos por el camino reverse necesitamos conocer el *kernel reverse*. Es decir, necesitamos conocer las distribuciones $q(x_{t-1}|x_t)$ que nos indican cómo devolvernos por el camino inverso. Sin embargo, no conocemos estas distribuciones y por eso necesitamos una forma de aproximarlas.

Aproximación del proceso reverse de difusión

El poder de los modelos de difusión consiste en que no añadimos mucho ruido en un solo paso, si no que añadimos muy poco ruido en cada paso, eventualmente realizando muchos pasos. El efecto acumulativo de todas estas pequeñas cantidades de ruido es lo que hace que la imagen final x_T sea prácticamente ruido puro. Sin embargo, en un paso individual del proceso hemos añadido muy poco

ruido, por lo que intuitivamente es más fácil predecir 'cuál es el ruido que debemos quitar en ese paso'. Es decir, es más fácil modelar la distribución reversa en un solo paso $q(x_{t-1}|x_t)$ que es la distribución que queremos aproximar. Esto nos motiva la siguiente aproximación:

Proponemos aproximar a $q(x_{t-1}|x_t)$ con una distribución gaussiana que llamamos $p_\theta(x_{t-1}|x_t)$ y que va a depender de un parámetro θ . Es decir, $p_\theta(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_\theta(x_t, t), \Sigma_\theta(x_t, t))$. Esto significa que $p_\theta(x_{t-1}|x_t)$ va a seguir una distribución gaussiana con media $\mu_\theta(x_t, t)$ y con matriz de covarianza $\Sigma_\theta(x_t, t)$. Estos parámetros de esta distribución van a depender a su vez del parámetro θ . Nuestro objetivo ahora será encontrar el parámetro θ que mejor nos ayude a aproximar la distribución $q(x_{t-1}|x_t)$ y así tendremos que $p_\theta(x_{t-1}|x_t) \approx q(x_{t-1}|x_t)$.

Una vez encontremos este parámetro, tendremos finalmente una aproximación la distribución ideal de los datos $q(x_0)$ dada por $p_\theta(x_0)$ que será la distribución de los últimos datos de nuestra secuencia inversa aproximada. Es decir, la distribución de los datos, después de que les quitamos el ruido con nuestras aproximaciones $p_\theta(x_{t-1}|x_t)$.

Problema de optimización y función de pérdida

Como en todo problema de aprendizaje profundo, queremos encontrar una función de pérdida. Como nuestro problema fundamental es que nuestra aproximación de $p_\theta(x_0)$ sea lo más cercana a $q(x_0)$, necesitamos una medida de 'qué tan distintas son dos distribuciones de probabilidad'. Una de estas nociones es la *Divergencia de Kullback-Leibler* o *Divergencia KL* entre dos distribuciones. Esta cantidad se denota como:

$$D_{KL}(q(x_0) \parallel p_\theta(x_0)).$$

Por ahora, es suficiente pensar que esta cantidad mide 'qué tan lejos' están dos distribuciones. Por lo tanto, esta es precisamente la cantidad que queremos minimizar. Queremos que $p_\theta(x_0)$ y $q(x_0)$ estén lo más cerca posible.

Tras una serie de simplificaciones, es posible mostrar que esta ecuación se simplifica drásticamente y que esencialmente el problema se reduce a encontrar el parámetro θ que minimice la distancia entre las distribuciones $p_\theta(x_{t-1}|x_t)$ y $q(x_{t-1}|x_t, x_0)$. Es decir, que para cada paso de nuestro proceso reverso queremos que nuestra aproximación de ese paso reverso $p_\theta(x_{t-1}|x_t)$ sea lo más cercana a el verdadero paso reverso $q(x_{t-1}|x_t, x_0)$ cuando ya conocemos x_0 . Esto hace que ahora, nuestro proceso de aprendizaje sea más sencillo, pues recuerde que no conocemos $q(x_{t-1}|x_t)$, pero cuando condicionamos esta distribución a x_0 , es como si tuviéramos una 'referencia' hacia donde llegar. Es

decir, tomamos una imagen x_0 de nuestra base de datos y la usamos como referencia para guiar el proceso inverso. No conocemos exactamente el camino inverso que debemos aproximar, pero por lo menos, sabemos a qué punto queremos llegar. Y como tenemos tantos datos, podemos explotar esta propiedad para entrenar nuestro modelo. Esta idea se ejemplifica en la **Figura 3**.




Figura 3. Los caminos amarillos ilustran el proceso reverso cuando tenemos una imagen de referencia x_0 .

Siguiendo los caminos reversos

Se puede mostrar, que esta distribución reversa real para la cual tenemos una referencia $q(x_{t-1}|x_t, x_0)$ sí la conocemos, la podemos parametrizar y también es una gaussiana. Se puede mostrar que podemos caracterizar esta distribución como

$$q(x_{t-1}|x_t, x_0) = \mathcal{N}(x_{t-1}; \tilde{\mu}(x_t, x_0), \tilde{\Sigma}(t)).$$

Donde la media de esta distribución $\tilde{\mu}(x_t, x_0)$ depende únicamente de los parámetros β_t que definimos para el proceso forward y de x_0 y x_t donde x_0 va a ser una muestra de nuestro conjunto de datos y x_t es esa misma muestra tras ser contaminada por ruido en el tiempo t . De igual forma, la matriz de covarianza de esta distribución $\tilde{\Sigma}(t)$ depende únicamente de los parámetros β_t del proceso forward y del tiempo t .

Como queremos que $p_\theta(x_{t-1}|x_t)$ y $q(x_{t-1}|x_t, x_0)$ estén lo más cerca posible y sabemos que ambas son distribuciones gaussianas, el problema se reduce a que sus medias y matrices de covarianza sean lo más parecidas posible. Empecemos por las matrices de covarianza:

Como $\tilde{\Sigma}(t)$ únicamente depende del tiempo y de los parámetros β_t , podemos hacer que la matriz de covarianza de $p_\theta(x_{t-1}|x_t)$ sea exactamente $\tilde{\Sigma}(t)$. Es decir, hacemos $\Sigma_\theta(x_t, t) = \tilde{\Sigma}(t)$ y así ya encontramos la matriz de covarianza para $p_\theta(x_{t-1}|x_t)$ que mejor aproxima a la matriz de covarianza de $q(x_{t-1}|x_t, x_0)$.

Para hallar la media $\mu_\theta(x_t, t)$ de $p_\theta(x_{t-1}|x_t)$ que mejor aproxime a $\tilde{\mu}(x_t, x_0)$ se puede mostrar es equivalente a resolver el siguiente problema de optimización (recuerde que esta media depende del parámetro θ):

$$\theta^* = \underset{\theta}{\operatorname{argmin}} \frac{1}{2\sigma(t)^2} \|\mu_\theta(x_t, t) - \tilde{\mu}(x_t, x_0)\|.$$

Donde $\sigma(t)^2 I = \tilde{\Sigma}(t)$. Esta será nuestra versión final de la función de pérdida. Si logramos hallar el parámetro θ que minimice esa cantidad, estaríamos encontrando la distribución $p_\theta(x_{t-1}|x_t)$ que mejor se aproxime a $q(x_{t-1}|x_t, x_0)$.

Solución del problema de optimización

Lo que haremos será parametrizar la media $\mu_\theta(x_t, t)$ con una red neuronal. Es decir, diseñaremos una red neuronal que tome como entradas la imagen ruidosa x_t y el tiempo t y la red neuronal intentará predecir el valor de la media $\mu_\theta(x_t, t)$. Luego, podemos pensar que θ representa todos los parámetros de esta red neuronal. Para el caso de imágenes, utilizaremos una red neuronal convolucional y θ representará los pesos, sesgos y kernels de esta red neuronal.

Entonces lo que hacemos es lo siguiente: le damos como entrada a nuestra red neuronal una imagen ruidosa x_t y el tiempo t . Esta muestra x_t la podemos obtener tomando una muestra x_0 de nuestra base datos y aplicarle el proceso forward hasta el tiempo t . Luego, la red neuronal nos da como salida un valor estimado de $\mu_\theta(x_t, t)$. Luego, como conocemos x_t, x_0 y todos los parámetros del proceso forward β_t , podemos calcular de forma directa los valores de $\tilde{\mu}(x_t, x_0)$ y de $\sigma(t)^2$ y así,

podremos calcular la pérdida en la que incurre nuestra red neuronal para esa predicción de $\mu_\theta(x_t, t)$ utilizando nuestra función de pérdida

$$\frac{1}{2\sigma(t)^2} \|\mu_\theta(x_t, t) - \tilde{\mu}(x_t, x_0)\|.$$

Esto se ilustra en la Figura 4:




Figura 4. La red neuronal toma como entrada un dato contaminado con ruido hasta el tiempo t y da como salida una estimación del valor de $\mu_\theta(x_t, t)$. En esta figura θ representa todos los parámetros de la red que pueden ser pesos, sesgos o kernels en una red neuronal convolucional.

Luego, utilizamos los algoritmos de retropropagación y descenso de gradiente para actualizar los parámetros θ de la red y repetimos este proceso con toda nuestra base de datos hasta que disminuyamos lo suficiente nuestra función de pérdida. Tras esto, detenemos el entrenamiento y ya obtendríamos nuestros parámetros θ que hacen que $\tilde{\mu}(x_t, x_0)$ y $\mu_\theta(x_t, t)$ estén lo más cerca posible y que por lo tanto $p_\theta(x_{t-1}|x_t)$ y $q(x_{t-1}|x_t, x_0)$ estén lo más cerca posible que era precisamente lo que queríamos. Siguiendo todo el hilo de argumentos, con esto tendremos finalmente una buena aproximación a la distribución ideal de los datos $q(x_0)$ dada por $p_\theta(x_0)$.

Bibliografía

Ho, J., Jain, A., & Abbeel, P. (2020). Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*, 33, 6840-6851.



© - **Derechos Reservados:** la presente obra, y en general todos sus contenidos, se encuentran protegidos por las normas internacionales y nacionales vigentes sobre propiedad Intelectual, por lo tanto su utilización parcial o total, reproducción, comunicación pública, transformación, distribución, alquiler, préstamo público e importación, total o parcial, en todo o en parte, en formato impreso o digital y en cualquier formato conocido o por conocer, se encuentran prohibidos, y solo serán lícitos en la medida en que se cuente con la autorización previa y expresa por escrito de la Universidad de los Andes.

De igual manera, la utilización de la imagen de las personas, docentes o estudiantes, sin su previa autorización está expresamente prohibida. En caso de incumplirse con lo mencionado, se procederá de conformidad con los reglamentos y políticas de la universidad, sin perjuicio de las demás acciones legales aplicables.
