

Clasificación de Sentimientos de Reseñas de Películas en IMDb con Redes Neuronales Recurrentes

Yezid Garcia*, Juan Martin Santos*, Jaime Rodriguez*

*Grupo 24. Códigos: 200810710, 202013610, 200717791

Abstract—Se presenta un modelo de red neuronal recurrente bidireccional (BiLSTM) para clasificar el sentimiento de reseñas de películas del conjunto de datos IMDb como positivo o negativo. El pipeline de preprocesamiento aplica eliminación de etiquetas HTML, filtrado de caracteres, eliminación de palabras funcionales y lematización. Los embeddings se inicializan con vectores GloVe de 100 dimensiones y se ajustan mediante una estrategia de entrenamiento progresivo que congela los embeddings en las primeras épocas y los desconecta con tasa de aprendizaje reducida. El modelo alcanza una precisión de 0.877, un recall de 0.910 y un F1-score de 0.893 sobre 4000 muestras de prueba.

I. INTRODUCCIÓN

El análisis de sentimiento es una tarea del procesamiento de lenguaje natural (NLP) que determina la polaridad emocional de un texto. Su aplicación en reseñas de películas permite caracterizar la opinión del público de forma automática, con utilidad en sistemas de recomendación y monitoreo de reputación. Los enfoques clásicos basados en frecuencia de términos ignoran el orden de las palabras y pierden información contextual.

Las redes neuronales recurrentes con celdas LSTM [1] superan esta limitación al procesar secuencias de tokens y capturar dependencias entre palabras distantes. La variante bidireccional (BiLSTM) combina estados ocultos de ambas direcciones, proporcionando a cada posición acceso al contexto anterior y posterior. Las representaciones distribucionales de palabras [2] asignan a cada término un vector denso entrenado sobre grandes corpus; inicializar un modelo con vectores preentrenados como GloVe [3] mejora la generalización cuando el conjunto de entrenamiento es de tamaño moderado.

Este trabajo describe la implementación y evaluación de un modelo BiLSTM con embeddings GloVe para la clasificación binaria de reseñas del conjunto IMDb. Se reportan precisión, recall y F1-score, se compara el rendimiento entre fases de entrenamiento y se examinan los patrones de comportamiento del modelo.

II. METODOLOGÍA

A. Conjunto de datos

El conjunto de datos contiene 40 000 reseñas de IMDb [4] con etiqueta binaria de sentimiento. La distribución es balanceada: 20 000 muestras positivas y 20 000 negativas. No se encontraron valores nulos ni texto vacío. La división es estratificada por clase:

- Entrenamiento: 80 % (32 000 muestras)

- Validación: 10 % (4 000 muestras)
- Prueba: 10 % (4 000 muestras)

B. Preprocesamiento

Cada reseña pasa por cinco pasos: eliminación de etiquetas HTML; descarte de caracteres no alfabéticos; conversión a minúsculas; eliminación de palabras funcionales usando NLTK [9]; y lematización. Los tokens se convierten a índices enteros con un vocabulario construido solo sobre el conjunto de entrenamiento. Las secuencias se rellenan o truncan a 300 tokens.

C. Embeddings GloVe

Los embeddings se inicializan con vectores GloVe de 100 dimensiones [3]; la cobertura sobre el vocabulario es del 77.2 %. Para estabilizar el entrenamiento, los embeddings se congelan durante las primeras tres épocas y luego se descongelan con una tasa de aprendizaje diez veces menor. Esta estrategia de ajuste progresivo, formalizada en [6], evita destruir la información semántica preentrenada.

D. Arquitectura del modelo

El modelo encadena cuatro etapas descritas en la Tabla I. La capa de embedding proyecta cada índice al espacio vectorial GloVe. La capa BiLSTM de 128 unidades por dirección (256 en total) procesa la secuencia en ambos sentidos. Un promedio sobre los estados ocultos de todas las posiciones de la secuencia (mean pooling) produce una representación de longitud fija; [7] demuestra que esta operación es superior al uso del último estado oculto para tareas de clasificación. Una capa lineal con activación sigmoide proyecta al espacio de probabilidad para la clasificación binaria.

TABLE I
CAPAS DEL MODELO *SentimentBiLSTM*.

Capa	Dimensión de salida	Parámetros
Embedding GloVe 100d	$B \times 300 \times 100$	7,449,500
Abandono ($p = 0.3$)	$B \times 300 \times 100$	0
BiLSTM (128 ud., 1 capa)	$B \times 300 \times 256$	267,264
Mean Pooling	$B \times 256$	0
Abandono ($p = 0.3$)	$B \times 256$	0
Lineal + Sigmoide	$B \times 1$	257
Total		7,685,277

E. Entrenamiento

El optimizador es Adam ($lr = 10^{-3}$) con pérdida de entropía cruzada binaria y tamaño de lote 128. El ciclo incorpora: un planificador que reduce la tasa de aprendizaje a la mitad si la pérdida de validación no mejora en dos épocas; limitación de la norma del gradiente a 1.0, crítico para LSTM según [5]; y parada anticipada con paciencia de cinco épocas. Las métricas de evaluación son precisión, recall y F1-score, calculadas sobre el conjunto de prueba al finalizar.

III. RESULTADOS

A. Resultados cuantitativos

La Figura 1 muestra la evolución de la pérdida en entrenamiento y validación, y de las métricas de validación por época. El entrenamiento se detuvo en la época 19 por parada anticipada.




Fig. 1. Pérdida BCE (izq.) y métricas de validación (der.) por época. La línea vertical implícita ocurre en la época 19, donde se activa la parada anticipada.

La Tabla II compara las métricas en tres momentos clave del entrenamiento para cuantificar el efecto de la estrategia de ajuste progresivo. La Tabla III reporta los resultados finales sobre el conjunto de prueba.

TABLE II
EVOLUCIÓN DE MÉTRICAS EN VALIDACIÓN POR FASE DE ENTRENAMIENTO.

Fase	Precisión	Recall	F1
Ép. 3 — embeddings congelados	0.811	0.895	0.851
Ép. 6 — inicio del ajuste fino	0.848	0.909	0.878
Ép. 11 — convergencia	0.889	0.894	0.892
Ép. 19 — parada anticipada	0.890	0.909	0.899

TABLE III
MÉTRICAS FINALES EN EL CONJUNTO DE PRUEBA (4 000 MUESTRAS).

Métrica	Valor
Precisión	0.877
Recall	0.910
F1-Score	0.893

B. Resultados cualitativos

El recall supera sistemáticamente a la precisión (0.910 frente a 0.877), lo que indica una tendencia del modelo a

clasificar como positivo ante la ambigüedad. Esto es consistente con el sesgo de los vectores GloVe: intensificadores frecuentes en reseñas como *amazing* o *terrible* tienen carga emocional pronunciada que el modelo asocia con la clase positiva incluso en contextos negativos. El efecto persiste tras el ajuste fino.

La convergencia es rápida en las primeras seis épocas (F1: 0.792 a 0.878); las épocas siguientes aportan mejoras marginales. La brecha creciente entre pérdida de entrenamiento y validación a partir de la época 11 señala sobreajuste moderado que la parada anticipada contiene pero no elimina.

IV. DISCUSIÓN

El F1 de 0.893 es consistente con rangos reportados en trabajos sobre IMDb con arquitecturas recurrentes [6]. El resultado se ubica en el rango esperado para una sola capa LSTM, ya que [5] muestra que capas adicionales no siempre mejoran el rendimiento y pueden introducir inestabilidad.

El mean pooling sobre los estados ocultos, respaldado por [7], produce representaciones más estables que el último estado oculto en reseñas largas donde el sentimiento está distribuido. La Tabla II confirma que el ajuste fino de embeddings aporta 2.7 puntos de F1 entre las épocas 3 y 6, en línea con [8] al comparar embeddings estáticos y ajustables.

Limitaciones: el número de épocas de congelado es fijo; las reseñas con más de 300 tokens se truncan perdiendo el contexto final, y no se realizó búsqueda sistemática de hiperparámetros.

Trabajo futuro: comparar con un codificador Transformer ligero, explorar mecanismos de atención como alternativa al mean pooling y evaluar distintas duraciones de la fase de congelado.

REFERENCES

- [1] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997.
- [2] T. Mikolov, K. Chen, G. Corrado, and J. Dean, “Efficient estimation of word representations in vector space,” *arXiv preprint arXiv:1301.3781*, 2013.
- [3] J. Pennington, R. Socher, and C. D. Manning, “GloVe: Global vectors for word representation,” in *Proc. EMNLP*, pp. 1532–1543, 2014.
- [4] A. L. Maas, R. E. Daly, P. T. Pham, D. Huang, A. Y. Ng, and C. Potts, “Learning word vectors for sentiment analysis,” in *Proc. 49th Annual Meeting of the ACL*, pp. 142–150, 2011.
- [5] K. Greff, R. K. Srivastava, J. Koutník, B. R. Steunebrink, and J. Schmidhuber, “LSTM: A search space odyssey,” *IEEE Trans. Neural Netw. Learn. Syst.*, vol. 28, no. 10, pp. 2222–2232, 2017.
- [6] J. Howard and S. Ruder, “Universal language model fine-tuning for text classification,” in *Proc. ACL*, pp. 328–339, 2018.
- [7] A. Conneau, D. Kiela, H. Schwenk, L. Barrault, and A. Bordes, “Supervised learning of universal sentence representations from natural language inference data,” in *Proc. EMNLP*, pp. 670–680, 2017.
- [8] Y. Kim, “Convolutional neural networks for sentence classification,” in *Proc. EMNLP*, pp. 1746–1751, 2014.
- [9] S. Bird, E. Klein, and E. Loper, *Natural Language Processing with Python*. O’Reilly Media, 2009.