



Clasificación Multi-Etiqueta de Artículos de Noticias de la BBC usando Transformers

Los artículos de noticias contienen una gran cantidad de información categórica y temática, con temas que abarcan desde política y tecnología hasta deportes y cultura. Muchos artículos pueden abarcar varios temas a la vez. Este proyecto tiene como objetivo desarrollar un sistema de clasificación multi-clase que pueda asignar una categoría a cada artículo de noticias de la BBC, utilizando la potencia de los modelos transformer para capturar el contexto y asignar etiquetas múltiples de manera precisa.

Introducción a los Transformers

Los modelos basados en transformers, como BERT, son especialmente adecuados para analizar texto debido a su capacidad para entender relaciones contextuales complejas entre palabras y frases. Esto permite a los transformers abordar de manera efectiva la clasificación multi-clase, capturando de manera simultánea la pertenencia de un artículo a múltiples temas sin necesidad de procesar secuencialmente, como ocurre en los modelos recurrentes.

Objetivo

- Desarrollar un modelo de clasificación multi-clase basado en transformers que identifique la categoría de artículos de noticias de la BBC.

Conjunto de Datos

- Utilizaremos un dataset de artículos de la BBC etiquetados con múltiples categorías temáticas, como "Sport", "Business", "Politics", "Tech", entre otros.
- Los datos los pueden obtener usando la siguiente línea de código en Python:
`kagglehub.dataset_download("jacopoferretti/bbc-articles-dataset")`

Actividades por Realizar

1. **Preprocesamiento del Texto:** Crear un pipeline para procesar los artículos, incluyendo la limpieza del texto, tokenización y la preparación de secuencias utilizando embeddings derivados de un modelo preentrenado como BERT. En

este paso se debe garantizar que el texto y las etiquetas estén en el formato adecuado para ser interpretado por el modelo de clasificación multi-clase.

2. **Implementación de la Arquitectura de Transformers:** Usar un modelo de transformers preentrenado, como BERT o RoBERTa, y adaptarlo a la clasificación multi-clase. Esto implicará añadir una capa de salida que permita al modelo generar una predicción de la categoría. Para ello, puede utilizar el método **BertForSequenceClassification**, disponible en la librería “transformers” vista en el laboratorio de la semana. Recuerde justificar la elección del modelo y de las capas adicionales, explicando cómo cada ajuste facilita la tarea de clasificación multi-clase.
3. **Entrenamiento y Evaluación del Modelo:** Dividir el dataset en conjuntos de entrenamiento, validación y prueba. Entrenar el modelo en el conjunto de entrenamiento y evaluar su rendimiento con el conjunto de prueba. Reportar métricas como precisión, recall, F1-score, y también un análisis de precisión para cada categoría, resaltando las categorías en las que el modelo presenta un mejor o peor rendimiento. Puede utilizar una GPU para entrenar el modelo durante 2 a 5 épocas, recuerde que el problema es un problema de clasificación multi-clase, donde la función de activación debería ser softmax.