

Clasificación de Sonidos de la Naturaleza usando el Audio Spectrogram Transformer (AST)

Jaime Rodriguez, Juan Martin Santos, Yezid Garcia — Grupo 24

Universidad de los Andes, Bogotá, Colombia

Códigos: 200717791, 202013610, 200810710

1. Introducción

La clasificación de sonidos del entorno natural tiene aplicaciones en monitoreo ambiental, conservación de biodiversidad y vigilancia ecológica. Identificar fuentes sonoras del ambiente permite caracterizar ecosistemas de manera no invasiva y a gran escala. Los métodos basados en características de audio tradicionales presentan limitaciones ante la variabilidad acústica de los sonidos naturales. Por otra parte, los modelos de aprendizaje profundo, como los transformers [1], han demostrado capacidad para extraer representaciones de datos secuenciales sin depender de características predefinidas.

El mecanismo de auto-atención de Transformers propuesto en [1] permite que los modelos capturen relaciones entre todos los elementos de una secuencia en una sola operación, lo que resulta adecuado para el análisis de representaciones de audio. El Audio Spectrogram Transformer (AST) [2] adapta esta arquitectura al dominio acústico: convierte señales de audio en espectrogramas MEL. AST superó a los enfoques convolucionales en múltiples benchmarks de clasificación de audio. El dataset ESC-50 [3] es una colección de referencia con 2000 grabaciones en 50 categorías de sonidos de ambiente, ampliamente usada para evaluar modelos de clasificación acústica.

El objetivo de este trabajo es adaptar el modelo AST preentrenado en AudioSet para clasificar sonidos naturales en cuatro categorías: aves, agua, viento y mamíferos. Se realiza fine-tuning del modelo MIT/ast-finetuned-audioset-10-10-0.4593 sobre un subconjunto del dataset ESC-50. El modelo se evalúa mediante precisión, recall y F1-score por categoría, y se analiza la matriz de confusión para identificar los patrones de error entre clases.

2. Metodología

A continuación se describen los componentes principales utilizados en el desarrollo del presente trabajo.

A. Pipeline general

Comprende cuatro etapas: (1) carga y filtrado del dataset a las cuatro categorías de interés, (2) extracción de características acústicas mediante el ASTFeatureExtractor, (3) fine-tuning del modelo AST, y (4) evaluación sobre el conjunto de validación.

B. Dataset y preprocesamiento

Se usa el dataset ESC-50 [3], cargado desde Hugging

Face como confit/esc50-demo con el fold 1. El conjunto de entrenamiento contiene 1600 muestras y el de validación 400, con 50 clases originales. Las 50 clases se mapean a cuatro super-categorías: aves, mamíferos, agua y viento. Las muestras sin categoría asignada se descartan. La Tabla 1 muestra la distribución resultante por categoría.

Tabla 1. Distribución de muestras por categoría tras el filtrado.

Categoría	Clases ESC-50 incluidas	Muestras (train)
aves	rooster, hen, chirping_birds, crow	128
agua	rain, sea_waves, water_drops, pouring_water, thunderstorm	160
mamiferos	dog, pig, cow, cat, frog, sheep	192
viento	wind	32

Cada grabación se remuestra a 16 kHz si es necesario. El extractor AST genera un espectrograma MEL normalizado y de tamaño fijo, asegurando consistencia entre muestras.

C. Arquitectura del modelo

Se usa el modelo MIT/ast-finetuned-audioset-10-10-0.4593 [2], preentrenado en AudioSet con 527 clases y aproximadamente 86 millones de parámetros. La capa de clasificación final (con 527 salidas) se reemplaza por una capa lineal con 4 salidas, una por cada categoría del proyecto. El resto de los pesos preentrenados se conservan para el fine-tuning.

D. Entrenamiento y métricas

El modelo se entrena durante 2 épocas con el optimizador AdamW, tasa de aprendizaje 1×10^{-4} y tamaño de lote de 8 muestras. La función de pérdida es la entropía cruzada. Se reportan precisión, recall y F1-score por categoría, métricas estándar para clasificación multiclase que permiten evaluar el desempeño de forma independiente por clase. La exactitud global (accuracy) complementa el análisis al igual que la matriz de confusión permitiendo identificar qué pares de categorías el modelo confunde con mayor frecuencia.

3. Resultados

Los resultados del modelo entrenado se interpretan desde

dos perspectivas, cuantitativa y cualitativa:

A. Resultados cuantitativos




Fig 1. Curva de pérdida (entropía cruzada) por época.

La Fig. 1 muestra la curva de pérdida promedio por época durante el entrenamiento en donde se ve una mejora notable así como la ausencia de más épocas.

Tabla 2. Métricas de clasificación.

Categoría	Precisión	Recall	F1-score
Agua	0.91	1	0.95
Aves	1	0.94	0.97
Mamíferos	0.96	1	0.98
Viento	1	0.50	0.67
promedio ponderado	0.96	0.95	0.95

La Tabla 2 presenta las métricas de clasificación por categoría, al tiempo que la Fig. 2 presenta la matriz de confusión sobre el conjunto de validación.




Fig 2. Matriz de confusión del modelo en el conjunto de validación.

El análisis por categoría (Fig. 2) muestra que las categorías con mayor variedad de clases ESC-50 mapeadas

presentan mayor cantidad de muestras de entrenamiento, lo que influye en el desempeño del modelo. La categoría viento, con una sola clase ESC-50 mapeada, cuenta con el menor número de muestras y menor desempeño.

B. Resultados cualitativos




Fig 3. Ejemplos de espectrogramas MEL.

La Fig. 3 presenta ejemplos de espectrogramas del conjunto de validación con la etiqueta real y la predicción del modelo. Los ejemplos de predicción correcta muestran que el modelo identifica con consistencia los patrones espectrales característicos de cada categoría: las aves presentan componentes de alta frecuencia con variaciones temporales rítmicas; los sonidos de agua exhiben energía distribuida en bandas de frecuencia amplias; el viento presenta energía predominante en frecuencias bajas con poca estructura temporal.

4. Discusión

El modelo AST muestra capacidad de transferencia desde AudioSet hacia la clasificación de sonidos naturales. La arquitectura de auto-atención [1], preentrenada en un corpus de audio de gran escala, captura representaciones espectrales reutilizables para tareas de clasificación en dominios relacionados. Este resultado es consistente con la observación en [2] de que el pre-entrenamiento en AudioSet generaliza a otras tareas acústicas.

Las diferencias de desempeño entre categorías se explican en parte por el desbalance en el número de clases ESC-50 mapeadas: mamíferos tiene seis clases (192 muestras de entrenamiento), agua tiene cinco (160 muestras) y aves cuatro (128 muestras), mientras que viento tiene una sola (32 muestras). La menor representación de viento limita la capacidad del modelo para aprender variantes intra-clase. Por otro lado, la similitud espectral entre vocalizaciones de aves y algunos sonidos de mamíferos puede generar confusión entre estas categorías.

A pesar de los buenos resultados, las limitaciones del presente trabajo incluyen: el número reducido de épocas de entrenamiento (2), el desbalance en el número de muestras por super-categoría, y la ausencia de técnicas de aumento de datos. Incrementar las épocas de entrenamiento, aplicar congelamiento parcial del encoder durante las primeras épocas, o balancear las super-categorías podría mejorar el desempeño del modelo en una futura versión.

5. Referencias

- [1] [1] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in Advances in Neural Information Processing Systems (NeurIPS), vol. 30, 2017.
- [2] [2] Y. Gong, Y.-A. Chung, and J. R. Glass, "AST: Audio Spectrogram Transformer," in Proc. Interspeech 2021, pp. 571–575, 2021. [Online]. Available: <https://arxiv.org/abs/2104.01778>
- [3] [3] K. J. Piczak, "ESC: Dataset for Environmental Sound Classification," in Proc. 23rd ACM International Conference on Multimedia (ACM MM), pp. 1015–1018, 2015.